



110 实验室前沿技术分组研究与专题汇报

开题报告

研究题目	基于深度学习的点云降噪任务研究		
课题类型	算法实验类		
应用场景与演示方式	现场模糊点云降噪效果演示	指导教师/带教学长	无
小组成员	姓名	学号	专业
1	谢博睿	2024213728	智能科学与技术+数学与应用数学双学位
2	马安	2024213786	智能科学与技术+数学与应用数学双学位
3	王浩宇	2024213736	智能科学与技术+数学与应用数学双学位
4			
课题研究目的和意义（含国内外研究相关工作综述）： 一、课题研究目的与意义 1. 研究背景与问题 随着三维扫描、自动驾驶、工业重建等技术的快速发展，点云作为三维场景的核心数据载体，其质量直接影响后续任务的精度与可靠性。然而，真实场景中采集的点云数据不可避免地包含各类噪声（如高斯噪声、离群点、非均匀噪声），严重影响点云的几何结构完整性与应用价值。传统点云去噪方法在处理复杂噪声场景时存在明显短板： 对噪声分布缺乏感知能力，难以自适应处理不同类型、不同强度的噪声； 基于 Score-Denoise 的扩散式去噪方法精度高，但迭代步数多、推理速度慢，难以满足实时性需求。针对以上痛点，本课题以 Score-Denoise 框架为基础，围绕鲁棒性、高效性两大目标展开改进研究。 2. 研究目的 本课题旨在提出一种面向高效、鲁棒的点云去噪方法，核心目标包括： 提升方法的鲁棒性：通过噪声自适应感知机制，让模型能自适应处理不同类型、不同强度的噪声，在复杂场景下保持稳定的去噪效果； 提升方法的高效性：通过改进 Score 网络与多维度加速策略，大幅降低推理迭代步数，在保证精度的前提下显著提升去噪速度； 构建完整的端到端点云去噪框架，为三维扫描、自动驾驶、工业检测等实际场景提供高效、可靠的去噪解决方案。 3. 研究意义 理论意义： 提出了噪声自适应感知与建模方法，为点云去噪模型引入噪声分布先验，突破了传统方法对噪声不敏感的局限； 探索了基于知识蒸馏与少步迭代的 Score-Denoise 加速路径，为扩散式点云去噪的高效推理提供了新思路。 应用价值： 为三维扫描数据提供高质量去噪支持，提升后续重建、测量任务的精度； 为自动驾驶、机器人环境感知等实时性场景提供高效去噪方案，满足低延迟、高鲁棒性的需求； 为工业检测与逆向工程提供可靠的点云预处理工具，降低噪声对几何特征提取的干扰。 二、国内外研究相关工作综述 1. 传统点云去噪方法			



传统点云去噪方法主要分为滤波类方法与优化类方法：

滤波类方法：如统计滤波、半径滤波、双边滤波等，通过统计邻域信息剔除离群点、平滑点云。这类方法计算简单，但对非均匀噪声、复杂曲面的处理效果差，易导致边缘细节丢失。

优化类方法：如基于 $L1/L2$ 正则化的点云重建方法、基于移动最小二乘（MLS）的曲面拟合方法，通过拟合局部曲面实现去噪。这类方法对参数敏感，且在处理大规模点云时效率低下，泛化能力有限。传统方法普遍依赖人工设计的规则与参数，难以自适应复杂噪声场景，且在处理非均匀、高密度噪声时鲁棒性不足。

2. 基于深度学习的点云去噪方法

近年来，深度学习方法凭借强大的特征学习能力，成为点云去噪的主流方向：

基于点 / 体素的直接回归方法：如 PointNet、PointNet++、DGCNN 等，通过学习点云的局部与全局特征，直接预测干净点云或噪声偏移。这类方法端到端效率高，但缺乏对噪声分布的建模，对复杂噪声场景的泛化能力较弱。

基于生成模型的去噪方法：如 GAN、VAE 等生成模型，通过学习干净点云的分布，实现含噪点云的重建。这类方法能生成高质量的点云，但训练难度大，易出现模式崩溃，且对噪声强度变化的鲁棒性不足。

基于扩散模型（Score-Denoise）的去噪方法：近年来兴起的扩散式点云去噪方法，如 Score-Denoise，通过逐步预测点云的 Score 梯度，迭代修正含噪点云，实现了高精度的去噪效果。但这类方法存在明显缺陷：

迭代步数多（通常需要 50 步以上），推理速度慢，难以满足实时性需求；

对不同噪声场景缺乏自适应机制，在噪声强度、类型变化时性能下降明显。

3. 现有研究的不足与本课题的创新切入点

综合国内外研究现状，现有点云去噪方法仍存在两大核心痛点：

鲁棒性不足：多数方法缺乏对噪声分布的感知能力，无法自适应处理不同类型、不同强度的噪声，泛化能力弱；

效率与精度难以兼顾：高精度的 Score-Denoise 方法迭代步数多、推理速度慢，而快速方法又难以保证去噪精度。针对以上不足，本课题从两个方向进行创新改进：

引入噪声自适应模块，让模型感知并建模噪声分布，提升对多噪声场景的鲁棒性；

提出快速 Score 去噪加速策略，通过少步迭代、知识蒸馏等方法，在保证精度的前提下大幅提升推理速度。



研究目标：

1. 总体目标

本课题的总体目标是：在经典 Score-Denoise 框架基础上，提出一套集噪声自适应感知、快速 Score 去噪于一体的点云去噪方法，在保证或提升去噪精度的前提下，实现更高的推理效率、更强的噪声鲁棒性，为真实场景下的点云数据处理提供一套高效、可靠的解决方案。

2. 具体目标（分模块、可落地）

目标 1：构建噪声自适应感知机制，提升多噪声场景鲁棒性 设计并实现噪声分析网络，能够自动识别点云的噪声类型（高斯 / 离群 / 非均匀）、噪声等级（轻 / 中 / 重）与局部密度信息，生成结构化噪声表示。 建立基于噪声分布的自适应去噪策略，使模型能够针对不同噪声场景采用差异化处理方式，提升方法在复杂噪声环境下的泛化能力与稳定性。 通过单元测试与对比实验，验证噪声自适应模块在不同噪声场景下的鲁棒性，确保噪声感知准确率达到预期要求。

目标 2：实现快速 Score 去噪加速，兼顾精度与效率 改进以 DGCNN/Point Transformer 为骨干的 Score 网络，融合噪声自适应模块输出的噪声表示，实现更精准的 Score / 方向预测。 实现多维度加速策略：将原版 Score-Denoise 的迭代步数从 $T=50$ 压缩至 $T=5-10$ 步，通过知识蒸馏与一步预测机制，在保证去噪精度（CD、F1 指标与原版相当）的前提下，推理速度提升 3 倍以上。 优化网络结构与推理流程，降低显存占用，使模型能够在主流 GPU 上高效运行，具备实际部署可行性。

目标 3：完成端到端模型构建与实验验证 整合两大创新模块，搭建完整的端到端点云去噪训练框架，实现从含噪点云输入到干净点云输出的全流程处理。 构建包含多种噪声类型、不同噪声强度的点云数据集，设计多目标损失函数与训练策略，完成模型训练与调优。 开展与基线方法（Score-Denoise 原版、DGCNN、PointNet++ 等）的对比实验，验证本方法在精度、速度、鲁棒性上的综合优势。

目标 4：完成系统 Demo 与成果交付 实现点云去噪演示 Demo，支持含噪点云输入、去噪过程可视化、结果对比与导出，验证方法的实际应用效果。 完成课题相关的代码、数据集、实验报告、论文文档的整理与归档，形成完整的研究成果。



研究内容、技术路线与评价指标：

a. 主要研究内容

本课题的核心目标是在经典 Score-Denoise 框架基础上，围绕 **Score 去噪加速**、**噪声自适应感知** 两大创新点，实现一种高效、鲁棒的点云去噪方法。主要研究内容如下：

创新点一：面向多噪声场景的自适应感知与建模

突破传统点云去噪方法对噪声分布缺乏感知的局限，研究含噪点云中不同噪声类型（高斯、离群、非均匀噪声）、不同噪声等级（轻 / 中 / 重）的分布特征。

设计噪声分析网络，实现噪声类型识别、噪声程度分级、局部密度信息提取，生成结构化噪声表示向量，让模型能“看懂”噪。

研究基于噪声分布的自适应去噪策略，让模型针对不同噪声场景采用差异化处理，显著提升方法的鲁棒性与泛化能力。

创新点二：基于知识蒸馏与少步迭代的快速 Score 去噪加速

针对原版 Score-Denoise 迭代步数多、推理速度慢的问题，改进以 DGCNN/Point Transformer 为骨干的 Score 网络，融合噪声表示信息，实现更精准的 Score / 方向预测。

提出多维度加速策略：

少步迭代优化：将迭代步数从 $T=50$ 压缩至 $T=5-10$ 步，大幅降低计算开销。

知识蒸馏：用多步迭代的教师模型指导少步推理的学生模型，在保证精度的前提下实现加速。

一步预测：探索从含噪点云到干净点云的直接映射路径，进一步提升推理效率。

优化网络推理效率与显存占用，解决 Score-Denoise 难以部署的痛点。

b. 关键技术路线

本课题的技术路线以两大创新点为核心，形成 “**噪声自适应感知** → **快速 Score 去噪**” 的完整流水线：

技术路线 1：噪声自适应模块（创新点一）

输入：含噪点云数据

核心步骤：

噪声分析网络：以 MLP/Transformer 为编码器，提取点云局部与全局特征。

噪声分布感知：自动识别噪声类型、噪声等级与局部密度信息。

噪声表示生成：输出结构化噪声特征向量，为后续模块提供条件指导。

输出：噪声信息向量（为快速去噪模块提供自适应依据）

技术路线 2：快速 Score 去噪模块（创新点二）

输入：含噪点云 + 噪声自适应模块输出的噪声表示

核心步骤：

改进 Score 网络：以 DGCNN/Point Transformer 为骨干，融合噪声表示信息，预测点云 Score / 方向。

加速策略落地：

少步迭代优化：大幅减少迭代次数，降低计算量。

知识蒸馏训练：教师模型（多步）指导学生模型（少步），保证精度损失可控。

一步预测：探索直接映射路径，实现极速推理。

坐标更新：根据预测的 Score 更新点云坐标，生成多 Patch 初步去噪结果。

输出：多 Patch 初步去噪点云（高效完成局部去噪）

c. 实验流程

该模型是一个“先感知噪声、再快速去噪”的两阶段架构。

整体架构上，系统由两个核心模块串联而成：前端的噪声自适应模块负责诊断输入点云的噪声类型和程度，生成可指导后续处理的噪声表示；后端的快速 Score 去噪模块则利用这些信息，通过改进的 Score 网络预测点云更新的方向，以极少的迭代步数完成从脏点云到干净点云的重建。


系统流程大致为：含噪点云先送入噪声自适应模块，分析网络会判断它是高斯噪声、离群噪声还是非均匀噪声，并评估噪声的严重程度；这



些噪声表征随即注入去噪模块，作为条件信号引导去噪过程。去噪模块采用基于 Score 的迭代更新机制，但与原始方法需要几十步不同，这里通过知识蒸馏、一致性学习等加速策略，将步数压缩到个位数，甚至可以实现一步预测，直接从脏点云跳到干净点云。

两个模块各有侧重：前者解决鲁棒性和泛化性问题，让系统面对不同噪声分布时不至于失效；后者解决效率问题，在保精度的前提下大幅提升推理速度。整个架构追求的目标就是精度、速度和鲁棒性三者之间的最优平衡。

模型整体流程图如下：



d. 评价指标 (重点突出创新点对应的效果)

本课题的评价指标围绕两大创新点的核心目标设计，分为三类：

【创新点一：鲁棒性验证】多噪声场景下的精度指标

Chamfer Distance (CD)：不同噪声类型（高斯 / 离群 / 非均匀）、不同噪声等级（轻 / 中 / 重）下，去噪后点云与真实点云的距离误差，验证方法对噪声分布的鲁棒性。

F1-Score：不同噪声场景下的点云匹配度，反映噪声自适应策略对去噪完整性的提升效果。

精度波动范围：对比不同噪声场景下 CD、F1 的变化幅度，验证模型的泛化能力。

【创新点二：高效性验证】速度与效率指标

推理时间：单帧点云的去噪耗时，对比原版 Score-Denoise，验证加速策略的效果。

迭代步数：去噪过程的迭代次数，验证少步迭代优化的压缩效果（如从 50 步降至 5-10 步）。

显存占用：模型推理时的 GPU 显存占用，验证加速后模型的部署可行性。

吞吐量：单位时间内可处理的点云数量，验证大规模场景下的处理效率。

综合对比与应用验证

与基线方法（Score-Denoise 原版、DGCNN、PointNet++ 等）在上述指标上进行全面对比，验证本方法在**速度、鲁棒性**上的综合优势。

Demo 完成度：实现完整的点云去噪演示系统，验证方法在 3D 扫描、自动驾驶、工业重建等场景下的实际应用效果。



小组成员、任务分工与进度安排：

王浩宇：数据处理 + 模块 1（噪声自适应）优化 + 模块 2（快速 Score 去噪）优化

核心职责：数据全流程处理、两大核心模块开发

数据处理与准备

负责含噪点云数据集的准备、清洗、划分（训练 / 验证 / 测试集），构建不同噪声等级（轻 / 中 / 重）、不同类型（高斯 / 离群 / 非均匀）的模拟噪声数据；开发数据增强工具（旋转、缩放、抖动等），为模型训练提供多样化数据支撑；制定统一的数据格式标准，确保模块间输入输出的兼容性。

模块 1：噪声自适应模块开发与优化

搭建噪声分析网络，实现噪声类型识别、噪声程度分级与噪声表示生成；优化噪声感知算法，让模型能自适应不同噪声分布，为模块 2 提供稳定的噪声信息输入；完成模块 1 的单元测试，验证其在不同噪声场景下的鲁棒性。

模块 2：快速 Score 去噪模块开发与优化

搭建改进的 Score 网络（以 DGCNN/Transformer 为骨干），结合模块 1 输出的噪声表示，实现 Score / 方向预测。

实现加速策略：少步迭代优化（ $T=50 \rightarrow T=5-10$ 步）、知识蒸馏、一步预测等，在保证精度的前提下大幅提升推理速度。

优化网络推理效率，完成模块 2 的单元测试，验证去噪效果与速度指标。

协同对接

向马安提供论文、PPT、演示所需的技术细节、实验数据与可视化素材，支撑最终成果呈现。

答辩阶段协助马安准备模块 1/2 相关的技术问答，补充技术细节说明。

谢博睿：模型训练 + 全流程节点任务推进

核心职责：模型整体训练调优、项目关键节点文档与材料交付

模型整体训练与调优

搭建完整的端到端训练框架，整合三大模块，实现从含噪点云到干净点云的全流程训练。

设计并实现多目标损失函数（Chamfer Distance、法向一致性损失、曲面平滑损失、噪声建模损失、一致性约束损失）。

执行多种噪声混合训练、自适应噪声条件输入、知识蒸馏训练，完成模型调优与超参数搜索。

开展对比实验：与原版 Score-Denoise、DGCNN、PointNet++ 等模型对比，收集 CD、F1、PSNR、法向误差、推理时间、显存占用等关键指标数据。

项目关键节点文档与材料交付

开题阶段：主导完成开题报告撰写，重点负责研究背景、技术路线，在 5 月 7 日前提交完整开题文档。

中期阶段：梳理前半程进度与技术难点，汇总项目整体进展，在 5 月 18 日提交中期进度报告，并负责 5 月 20 日的中期硬件资源对接申请。

结题阶段：主导完成结题报告撰写，实验结果分析，在正式答辩前 5 个工作日提交结题文档。

协同对接

向马安提供完整的实验数据、模型结构说明、对比结果图表，支撑论文与 PPT 制作。

马安：成果呈现与项目统筹

核心职责：论文撰写 + UI 界面设计 + PPT 制作 + 最终演讲

论文撰写与统筹

梳理课题背景、研究现状、问题提出，完成论文引言与相关工作部分。

整合谢博睿，王浩宇的模块设计与实验结果，撰写方法部分（两大模块原理、网络结构、损失函数、训练策略）。

整理实验数据，撰写实验结果与分析部分，补充对比实验、ablation study、可视化结果。

完成论文结论、摘要、关键词撰写，统一论文格式与排版，负责论文修改与定稿。

UI 界面设计

设计点云去噪系统的可视化界面，支持含噪点云输入、去噪过程展示、干净点云输出与对比。

实现噪声等级选择、参数调节、结果导出等交互功能，提升系统易用性。



PPT 制作与演讲准备

提炼课题核心创新点、技术路线、实验结果，制作逻辑清晰、重点突出的汇报 PPT。

设计汇报流程，准备演讲讲稿，优化表达逻辑，确保能清晰展示课题的高效、鲁棒、全局一致性三大优势。

协同对接

定期收集并与谢博睿，王浩宇及时沟通讨论项目进展、关键数据、成果图片，确保论文与 PPT 内容准确。

协调项目进度，提醒关键节点，推动课题按计划完成。



预期成果/产出：

一、理论与方法成果

一套面向多噪声场景的点云去噪新方法提出并实现一套集噪声自适应感知、快速 Score 去噪于一体的端到端点云去噪方法，解决传统 Score-Denoise 方法推理速度慢、鲁棒性不足的两大痛点。

两大核心创新点的理论与技术方案

噪声自适应感知机制：实现对噪声类型、强度、分布的自动识别与建模，输出结构化噪声表示向量。

快速 Score 去噪加速方案：基于少步迭代、知识蒸馏与一步预测的多维度加速策略，实现精度与效率的平衡。

可发表 / 提交的课题论文 / 研究报告完成一篇完整的课题研究论文，涵盖背景、相关工作、方法、实验、结论等全章节内容，清晰阐述两大创新点的原理、实现与效果。

二、技术与系统成果

完整的端到端点云去噪模型代码库

包含两大模块（噪声自适应、快速 Score 去噪）的完整实现代码，附带详细注释与使用文档。

支持训练、验证、测试、推理全流程，代码可复现，适配主流深度学习框架与硬件环境。

优化后的快速 Score-Denoise 模型权重文件

经过多目标损失函数训练与超参数调优的最终模型权重，支持不同噪声场景下的快速推理。

包含原版与加速版模型权重，方便进行速度与精度的对比验证。

点云去噪演示 Demo 系统

实现可视化交互界面，支持含噪点云输入、去噪过程动态展示、结果对比与导出。

支持噪声等级选择、参数调节，直观展示本方法在不同场景下的去噪效果，可用于答辩与成果展示。

三、实验与验证成果

多场景、多指标的对比实验结果

与基线方法（原版 Score-Denoise、DGCNN、PointNet++ 等）的全面对比实验数据，包括 CD、F1、PSNR、法向误差等精度指标，以及推理时间、迭代步数、显存占用等效率指标。

不同噪声类型（高斯 / 离群 / 非均匀）、不同噪声等级（轻 / 中 / 重）下的鲁棒性测试结果，验证方法的泛化能力。

两大创新点的 Ablation Study 验证报告

通过移除 / 替换各模块的对比实验，验证快速去噪、噪声自适应两大创新点对模型整体性能的贡献度。

提供详细的实验数据、可视化对比图表与分析结论。

点云去噪效果可视化结果集

不同噪声场景下，含噪点云、初步去噪结果、全局优化后干净点云的对比可视化图片 / 视频。

重点展示 Patch 接缝处的平滑度、几何结构完整性，直观体现全局一致性优化的效果。

四、项目交付物成果

课题文档材料

开题报告 1 份（5 月 7 日前提交）

中期进度报告 1 份（5 月 18 日提交）

结题报告 / 论文 1 份（答辩前 5 个工作日提交）

汇报与答辩材料

课题汇报 PPT 1 份（答辩前 1 个工作日完成）

演示 Demo / 实验演示视频 1 份（答辩前 1 个工作日完成）

答辩讲稿与技术问答准备材料

项目归档材料

完整的项目代码、数据集、实验日志、模型权重归档包 1 份



实验数据、对比图表、可视化结果等所有支撑材料，整理成规范的项目成果包。

五、预期效果指标（可量化成果）

精度指标：在 CD、F1-Score、PSNR 等关键指标上，去噪效果不低于原版 Score-Denoise，部分场景下实现提升。

效率指标：推理迭代步数从 50 步压缩至 5-10 步，推理速度提升 3 倍以上，显存占用显著降低。

鲁棒性指标：在不同噪声类型、不同噪声等级场景下，CD、F1 指标的波动范围明显小于基线方法，泛化能力显著提升。



参考文献:

- 1.Luo S, Hu W. Score-Based Point Cloud Denoising[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2021: - 4592.
- 2.Rusu R B, Cousins S. 3D is here: Point Cloud Library (PCL)[C]//2011 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2011: 1 - 4.
- 3.Deep Learning on Point Sets for 3D Classification and Segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 652 - 660.
- 5.Deep Hierarchical Feature Learning on Point Sets in a Metric Space[C]//Advances in Neural Information Processing Systems (NeurIPS). 2017, 30.
- Rakotosaona M-J, La Barbera V, Guerrero P, et al. PointCleanNet: Learning to Denoise and Remove Outliers from Dense Point Clouds[J]. Computer Graphics Forum, 2020, 39(1): 185 - 203.
- 6.Wang Y, Sun Y, Liu Z, et al. Dynamic Graph CNN for Learning on Point Clouds[J]. ACM Transactions on Graphics (TOG), 2019, 38(5): 1 - 12.